Sistemas de Data Warehousing

Notas de Leitura

Orlando Belo

Departamento de Informática

Escola de Engenharia

Universidade do Minho

Índice

- Introdução.
- Fontes de Dados.
- Sistemas de Dados Heterogéneos.
- Património de Dados de uma Organização.
- Sistemas de Data Warehousing.
  - Características e Arquitectura Base.
  - Implementação e Administração.
  - Modelação Dimensional e Metadados.
  - Povoamento.
  - Data Marts.
- Sistemas de Processamento Analítico.
  - Características Base
  - Estruturas Multidimensionais.
  - Intervenientes e Operações OLAP
  - Povoamento.
- Notas Finais.

Introdução

- As empresas, para serem competitivas e reactivas às constantes mudanças e requisitos dos seus mercados, têm a necessidade de lidar com grandes volumes de informação e de avaliar essa mesma informação, devendo ser capazes e serem capazes de com ela tomar decisões.

- As suas bases de dados empresariais, ou a conjugação das suas diversas bases de dados departamentais, podem constituir excelentes fontes de informação que, quando devidamente exploradas, podem garantir vantagens significativas nos segmentos de mercado em que as empresas estão inseridas.

Fontes de Informação

- Porém, essas fontes de informação, ditas empresariais, apresentam graus de diversidade e heterogeneidade elevados, normalmente provocados por situações de:
  - Coordenação deficitária dos processos de desenvolvimento de software no seio das empresas.
  - Falta de planeamento e estratégias de recolha e armazenamento da informação empresarial.
  - Não integração e/ou conjugação das funcionalidades da empresa e dos recursos associados.
  - Natureza da própria informação.
  - (…)

Desempenho dos Sistemas

- Os sistemas de informação das empresas, que revelam taxas de crescimento acentuadas, tendem a alcançar, a curto ou médio prazo, estados de saturação ao nível dos seus sistemas de bases de dados.

- Esse grau de saturação pode surgir ao nível da capacidade de resposta a interrogações mais complexas, com maior grau de agregação e cálculo, provocando largos períodos de espera pela informação resultante dessas interrogações.

- A situação agrava-se quando o número de transacções gerado pelos processos correntes dos utilizadores é elevado, reduzindo o tempo de atenção do sistema operacional a essas interrogações.

Uma Situação Real

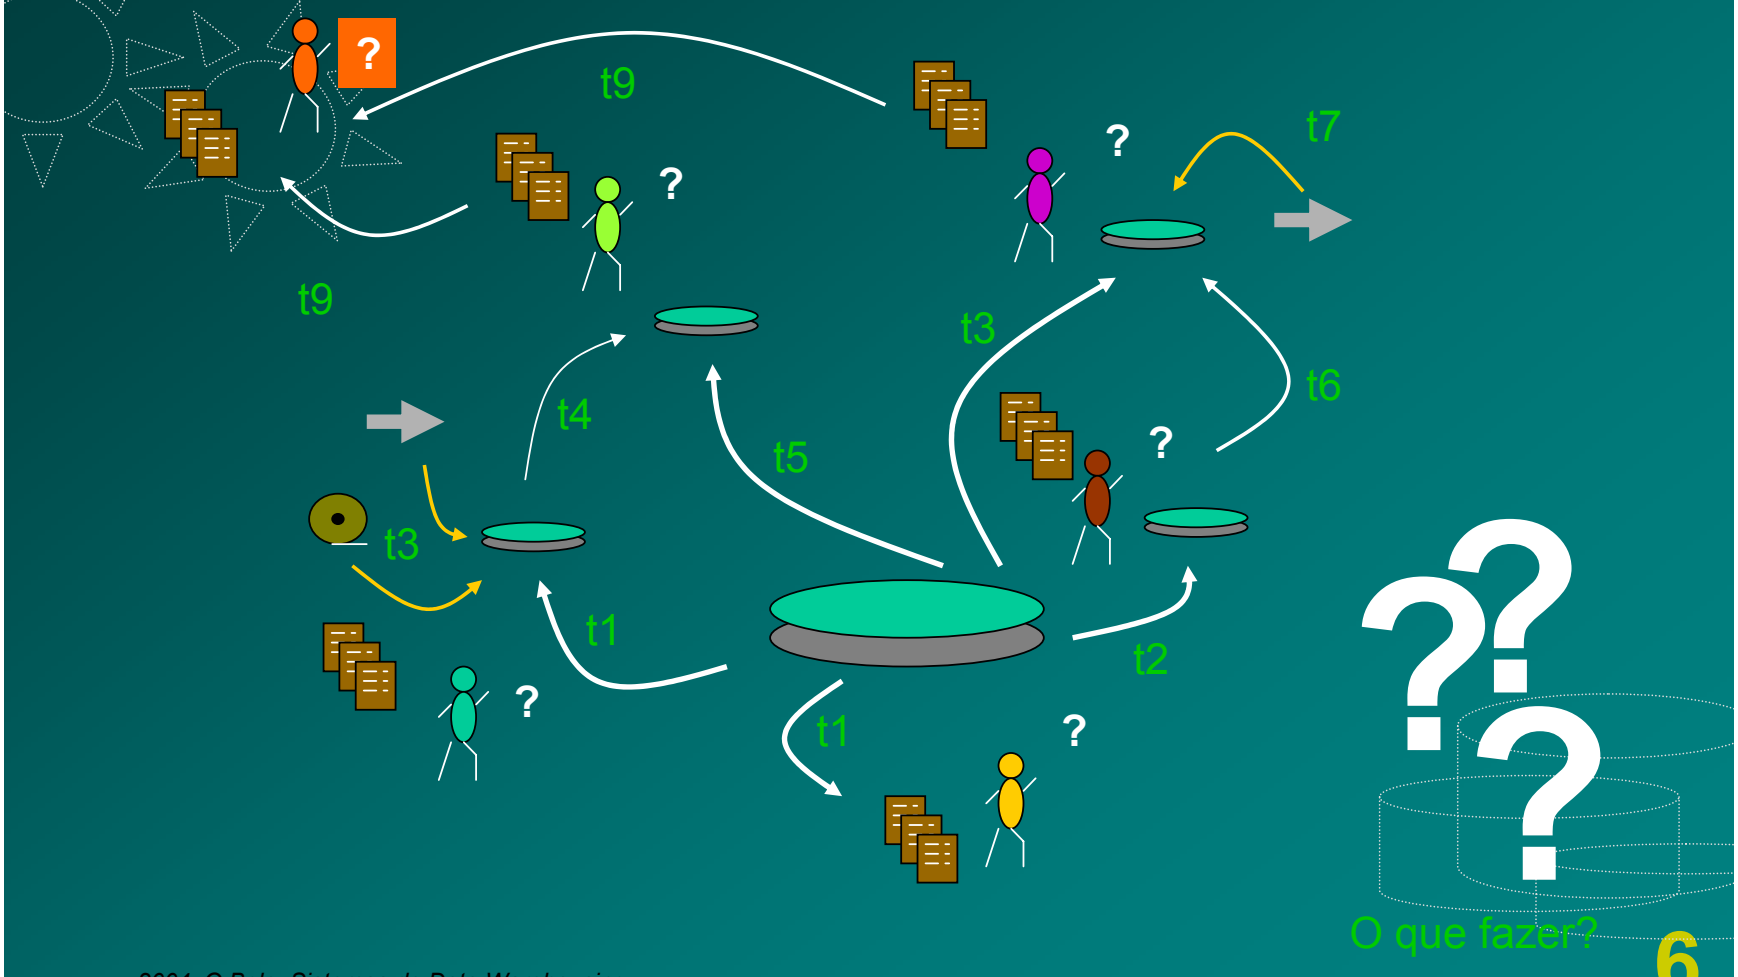

Um Sistema de Dados

- O efeito da diversidade e heterogeneidade das fontes de informação pode ser atenuado se, com base em critérios bem definidos de selecção, extracção, transformação e integração, os dados necessários aos processos de tomada de decisão contidos nas fontes de informação empresariais estiverem conciliados num único sistema de dados homogéneos.

Uma Situação Ideal

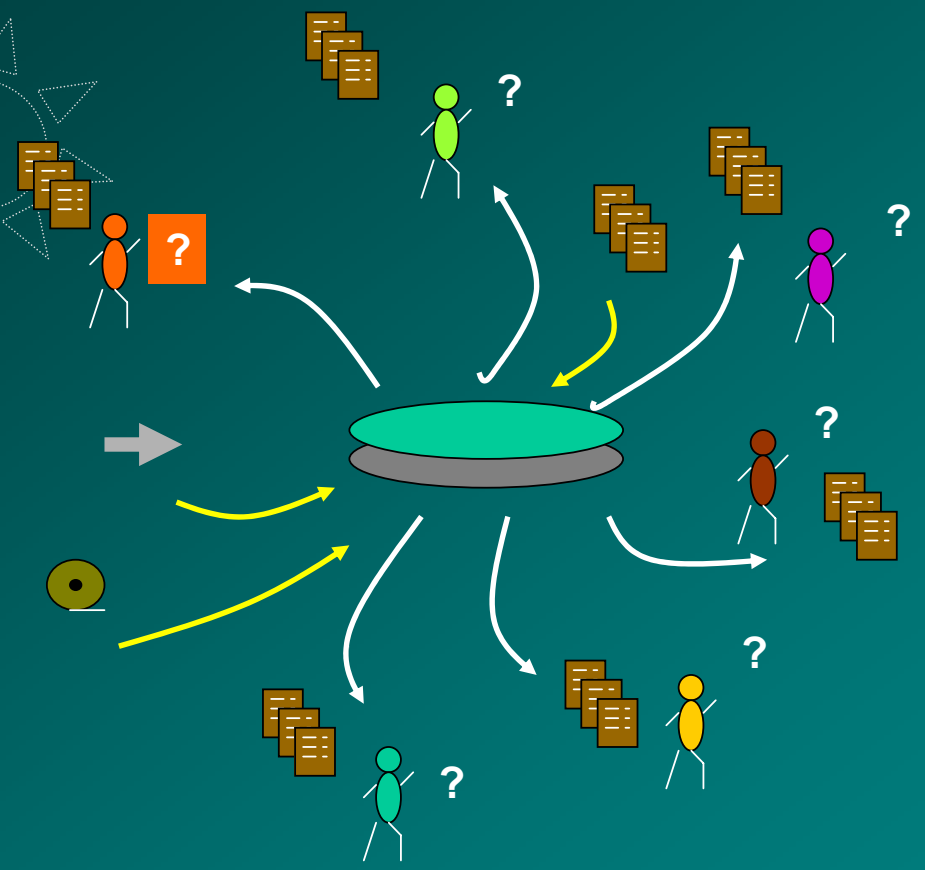

??
?

Será concretizável?

Património de Dados

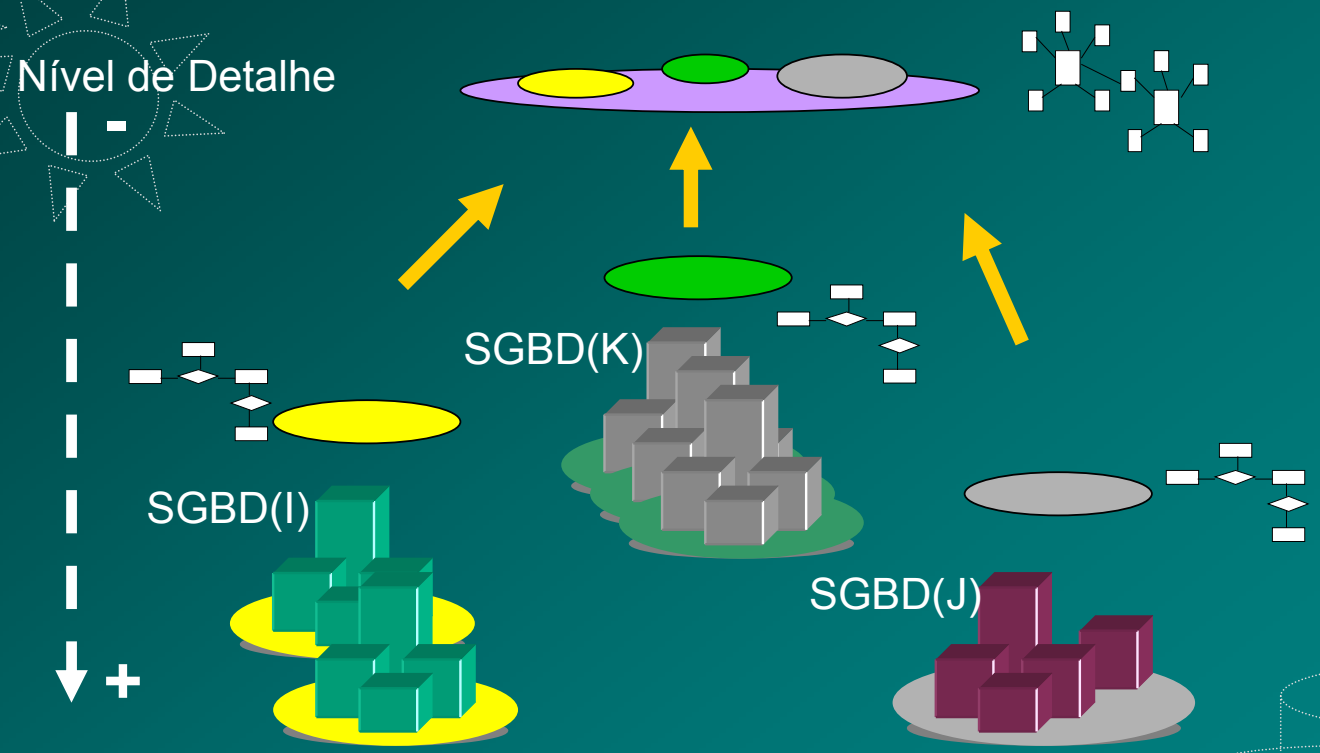

Organização dos Dados

- A organização dos dados nesse sistema tem que estar de forma a que as diversas solicitações de informação sejam satisfeitas rapidamente, sendo necessária a garantia de que:
  - Os dados armazenados sejam consistentes.
  - Os dados não sofram alterações ao longo do tempo.

Sistemas de Data Warehousing

- Os Sistemas de Data Warehousing (SDW) disponibilizam os meios e a tecnologia necessária para a criação desse sistema de dados e para o suporte de processos de gestão e tomada de decisões.

- Os SDW permitem integrar num único repositório de dados - o Data Warehouse (DW) - a informação que está distribuída pelos diversos sistemas de dados dos departamentos das empresas.

- A informação contida num DW está organizada por assuntos e não orientada para satisfazer os requisitos das aplicações informáticas de gestão existentes nas empresas, mas sim os requisitos operacionais da tomada de decisão, sendo os seus dados utilizados para análise e não para o processamento de dados corrente.

Sistemas de Data Warehousing

- Um SDW é, em termos gerais, um sistema que suporte processos de tomada de decisão baseado numa larga colecção de dados com as seguintes características:
  - Orientada por assuntos.
  - Integrada.
  - Temporal.
  - Não volátil.

Vantagens de um SDW

- Elevados desempenhos na satisfação de interrogações sobre os sistemas de dados.
- Os sistemas de dados do SDW estão permanentemente acessíveis, mesmo quando as fontes de informação não estão.
- O processamento de dados ao nível das fontes de informação não é afectado.
- Os sistemas de dados do SDW disponibilizam informação que as fontes de informação não contêm - agregação de dados e informação histórica.
- As interrogações não são visíveis no exterior do SDW.

Problemas a Considerar

- Má estimativa dos recursos envolvidos nos processos de carregamento.
- Problemas não detectados nas fontes de informação.
- Informação que é necessária e que os sistemas operacionais não contêm.
- Aumento das exigências dos utilizadores finais.
- Homogeneização de dados.
- Elevadas exigências em termos de recursos.
- Pertença dos dados.
- Elevada manutenção.
- Projectos de longa duração.
- Complexidade na integração de dados.

Requisitos Operacionais

- É preciso saber e decidir previamente quais os dados a armazenar no SDW.
- As interrogações só podem ser feitas no ambiente do SDW.
- É necessário saber a cada momento que tipos de modificações sofreram as fontes de informação e de que maneira elas afectam ou não o sistema de dados do SDW.

Sistemas OLTP vs SDW

OLTP

- Pequenas transacções
- Dimensão MB-TB
- Operações de actualização
- Dados elementares
- Utilizadores de aplicações operacionais
- Dados que reflectem um estado presente.

SDW

- Interrogações complexas e longas
- Dimensão GB-TB
- Operações de leitura
- Dados agregados ou consolidados
- Agentes de decisão e analistas
- Dados que permitem análises históricas.

Implementação de um SDW

- Além das tarefas de desenho e implementação do SDW, os projectistas deste tipo de sistemas têm que se preocupar com os custos de manutenção e com o tamanho físico (e taxas de crescimento) do DW.

- Uma das técnicas utilizadas para optimizar e melhorar o desempenho de um SDW é a desnormalização (parcial ou total) das tabelas que integram os esquemas de dados do DW conjugadas com a utilização extensiva de processos de indexação e agregação de dados.

- Porém, estas técnicas provocam aumentos significativos na dimensão da DW o que provoca também aumentos nos custos de segurança e de recuperação de dados e, consequentemente, nos custos de manutenção do SDW.

- Todos estes factores, naturalmente críticos, têm que ser ponderados e ajustados de acordo com as necessidades de informação e desempenhos requeridos pelos agentes de decisão.

Transformação e Integração

- Para que seja possível transformar os vários sistemas de dados de uma empresa, normalmente armazenados em sistemas tradicionais de bases de dados, em informação útil com altos padrões de qualidade num SDW, é necessário analisar e avaliar vários aspectos, nomeadamente:
  - a integração intencional de dados redundantes no seio do DW como forma de optimizar o desempenho do SDW.
  - a ocorrência de quebras na integridade e consistência dos dados.
  - a necessidade de um suporte de dados orientado ao assunto, tão completo quanto possível, para o desenvolvimento das actividades de gestão e de negócio.

Questões de Administração

- Análise dos dados com o objectivo de assegurar consistência.
- Transformação e junção de dados das fontes de informação para armazenamento temporário dentro das tabelas da DW.
- Criação de índices e views nas tabelas base.
- Definir e manter perfis de utilização.
- Avaliar e aplicar se necessário processos de desnormalização de dados.
- Avaliação e geração de agregações de dados.
- Definir planos para cópias de segurança e de arquivo de dados.
- Manutenção do catálogo geral do SDW.
- Definir e aplicar medidas de segurança.
- Planos de contingência para as operações críticas.

Metadados

- Metadados são dados acerca dos dados- podem ser interpretados como "instrumentos" de trabalho que qualquer administrador de um sistema de dados necessita para transformar os dados armazenados em informação.

- A camada de metadados de um SDW é um dos seus componentes fundamentais, contendo na sua estrutura informação como:

  - a localização e descrição dos vários componentes do SDW;
  - a definição, os nomes, a estrutura e o conteúdo do DW e das vistas dos utilizadores finais;
  - as regras de integração e transformação utilizadas durante os processos de carregamento de dados no DW;
  - informação acerca da história e das actualizações efectuadas sobre o DW;
  - modelos para análise e monitorização de dados; procedimentos de autenticação e segurança de dados; etc.

Arquitectura de um SDW

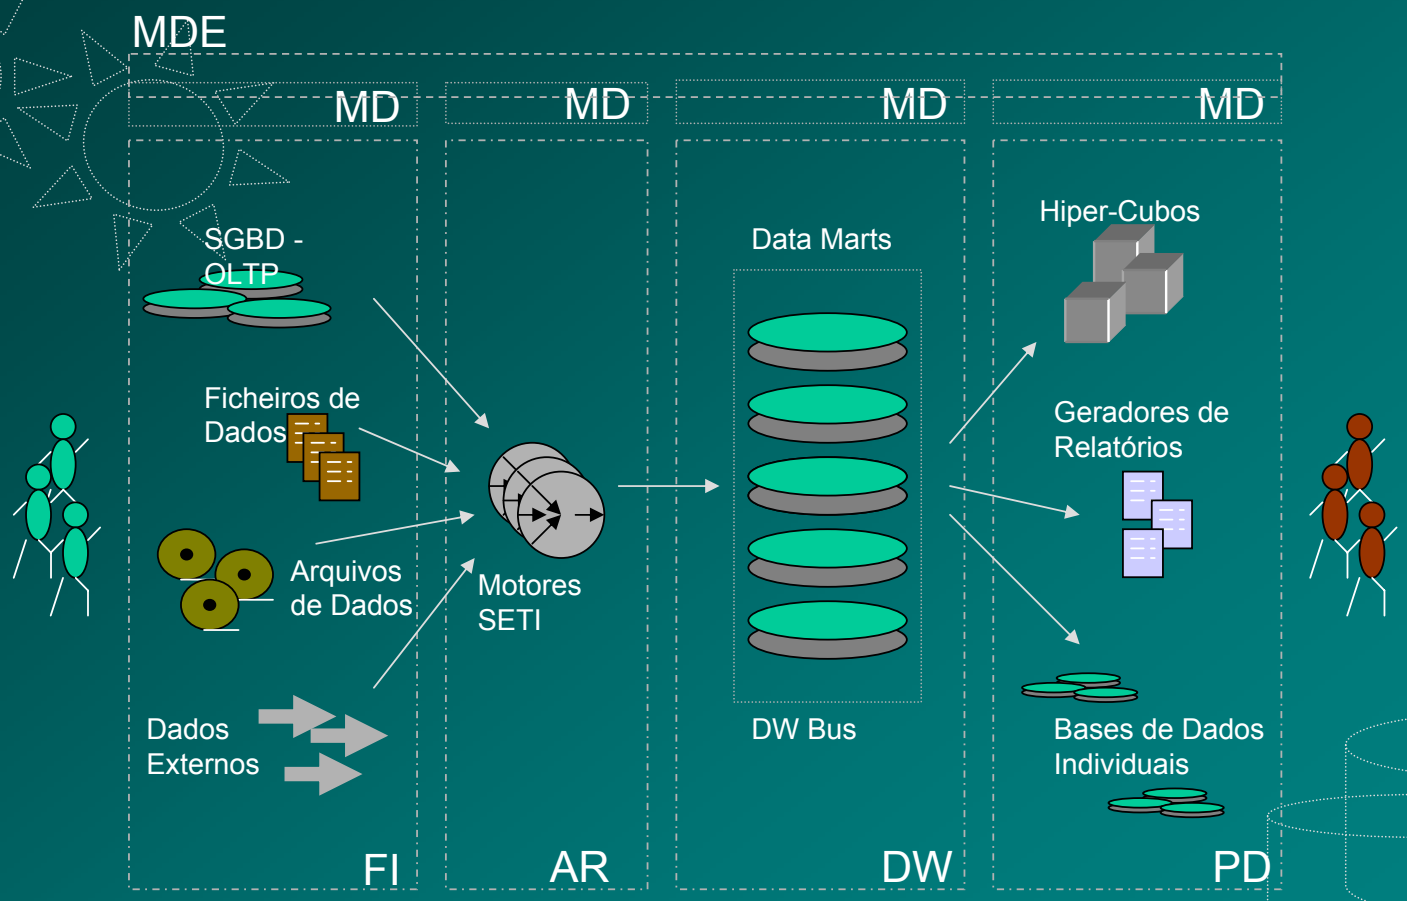

Fluxos de Dados num SDW

- Num SDW as tarefas relacionadas com o processamento de informação estão associadas directamente com os fluxos de informação que circulam no sistema, nomeadamente os fluxos de:
  - Entrada: extracção, limpeza e carregamento dos dados das fontes de informação.
  - Ascendente: sumariação, empacotamento e distribuição de dados.
  - Descendente: arquivo e cópias de segurança dos dados do sistema.
  - Saída: que disponibiliza os dados aos utilizadores do sistema.
  - Metadados: que permite gerir os metadados do SDW.

Ferramentas de Acesso

- A principal função de um SDW é disponibilizar aos utilizadores informação sobre os processos de negócio de uma empresa por forma a suportar as suas tarefas de tomada de decisão.

- Os principais tipos de ferramentas de acesso a um SDW são para:
  - Geração de relatórios e interrogações.
  - Desenvolvimento de aplicações.
  - Sistemas de informação para executivos – “EIS”.
  - Processamento analítico – “OLAP”.
  - Extracção de conhecimento – “Data Mining”.

Requisitos para um DW-RDBMS

- Bons desempenho no carregamento e processamento de dados.
- Gestão da qualidade dos dados.
- Bons desempenhos na satisfação de interrogações.
- Escalabilidade ao Terabyte.
- Capacidades de análise dimensional integradas.
- Funcionalidades para a elaboração de interrogações complexas em plataformas bastante amigáveis.
- Mecanismos para a gestão dos recursos do sistema, definição de prioridades nos processos, análise de carga e balanceamento e de afinação (“tuning”).

Data Marts

- Algumas das características que diferenciam os Data Marts das Data Warehouses são:
  - Os Data Marts contêm menos informação que as Data Warehouses, sendo assim mais navegáveis e de mais fácil compreensão.
  - Os Data Marts centram-se nos requisitos dos utilizadores associados com um departamento ou com uma unidade funcional de negócio em particular.
  - Os Data Marts não contêm normalmente informação detalhada com dados operacionais ao contrário das Data Warehouses.

A Criação de Data Marts

- Disponibilizar aos utilizadores a informação que eles precisam e que analisam de forma mais frequente.
- Melhorar o tempo de resposta ao utilizador final, com a diminuição do volume da dados a aceder.
- Simplificação dos processos de entrada no sistema já que necessitam de menos informação do que uma DW e não tão abrangente.
- O custo de implementação é normalmente melhora que o da implementação de uma DW.
- Permitem definir com mais precisão quais os utilizadores que irão usufruir dos seus dados.

Desenho de um DW

- Definição dos dados a armazenar no DW e conhecimento acerca dos seus formatos lógicos - esquemas dimensionais.
- Identificação das fontes de informação necessárias à satisfação dos dados requeridos pelo DW e conhecimento acerca dos seus formatos lógicos - esquemas conceptuais relacionais.
- Definição e selecção de recursos - hardware, software e humanos.

Um Esquema de um DW

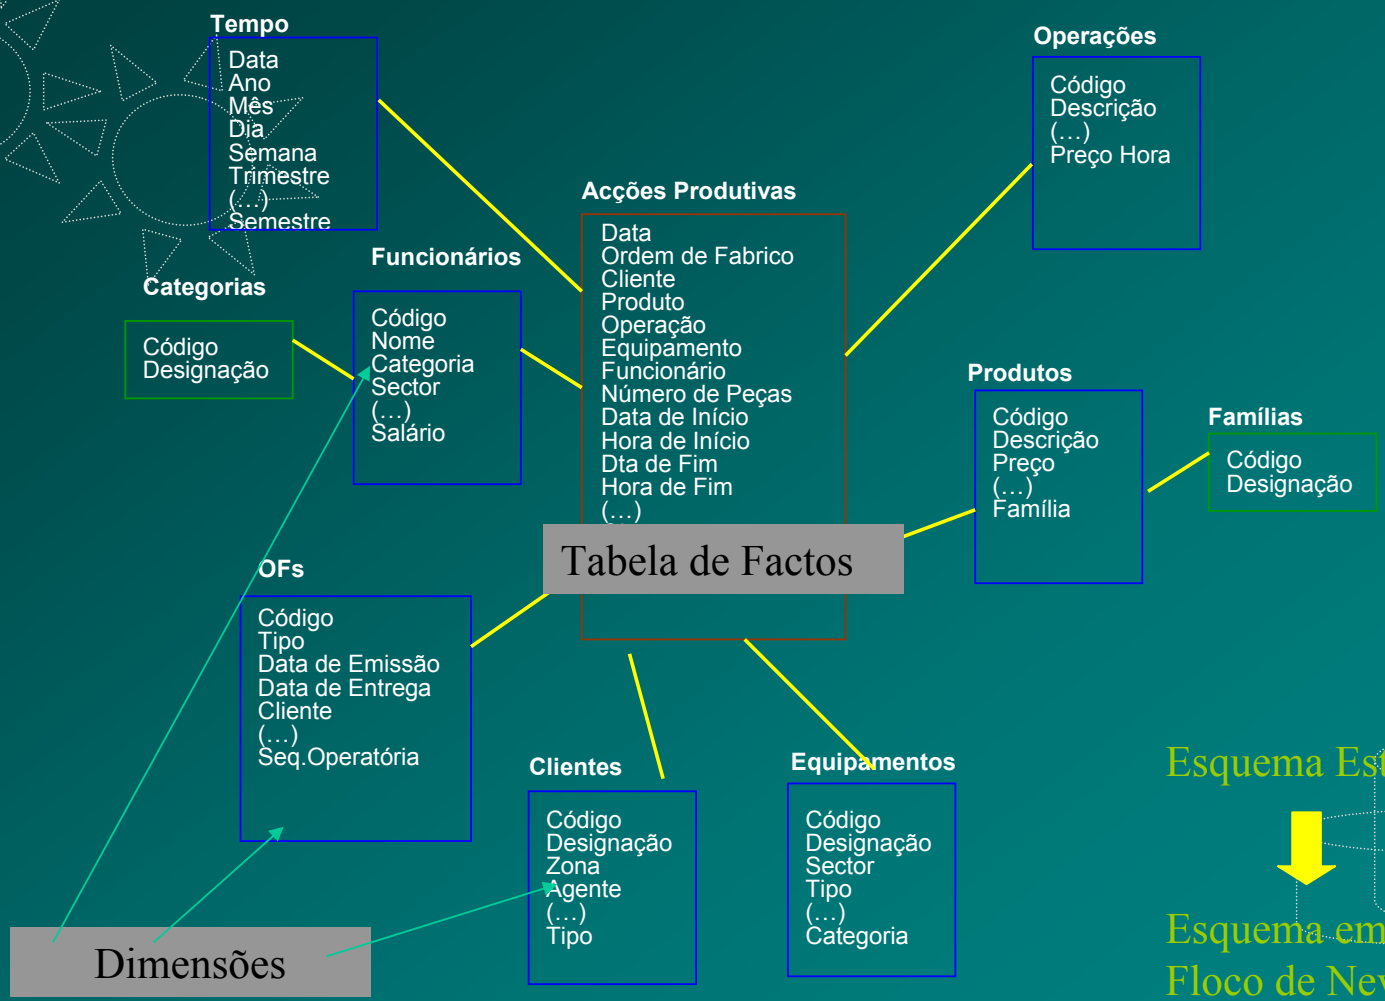

Esquema Estrela

Esquema em Floco de Neve

Requisitos das Tabelas de Factos

- Na arquitectura de um esquema para um DW, em particular para a(s) sua(s) Tabela(s) de Factos deve-se ter em consideração alguns aspectos, nomeadamente:
  - Identificar efectivamente o período de tempo de actualização para cada aplicação de suporte à decisão.
  - Identificar as necessidades em termos de dados para a elaboração de estatísticas relativamente à necessidade de dados com grande nível de detalhe.
  - Analisar e identificar se alguns dos atributos (colunas) das tabelas de factos podem ser removidos.
  - Reduzir tanto quanto possível as dimensões dos atributos das tabelas de factos e ao mesmo tempo verificar as caracterizações dos seus domínios.
  - Ponderar a utilização de chaves estrangeiras inteligentes ou não.
  - Analisar qual a melhor estratégia para "lidar" com o tempo nas tabelas de factos.
  - Verificar a viabilidade de particionamento das tabelas de factos no sentido de se alcançar estruturas de dados de mais fácil manutenção e manipulação.

Alimentação de um Esquema

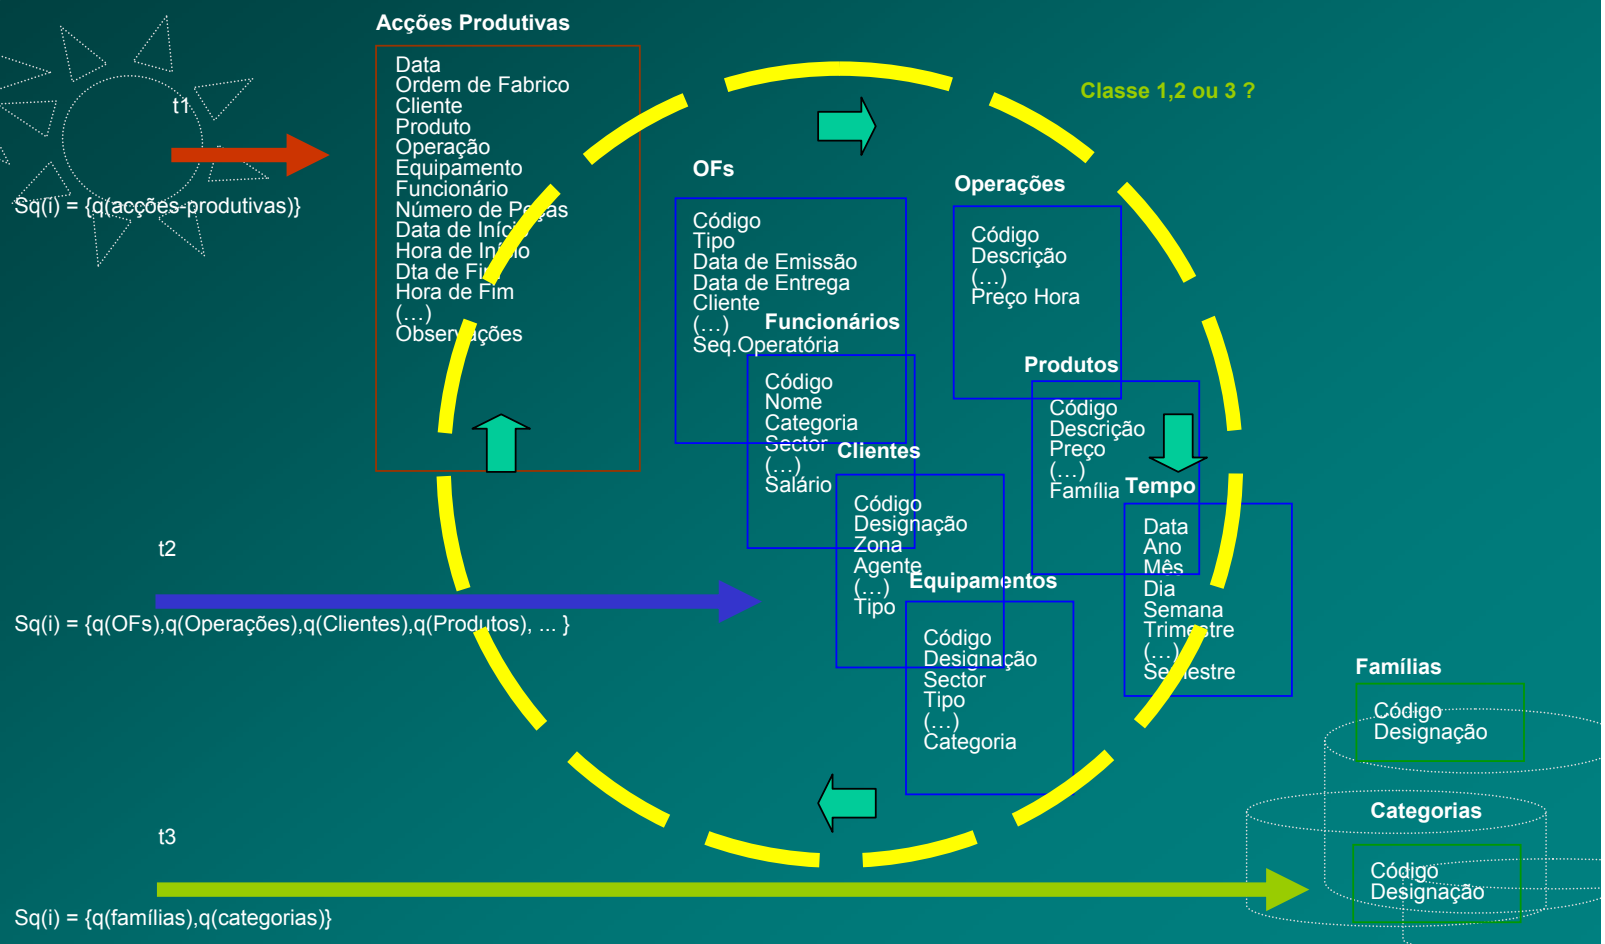

Sistemas OLAP

- Um dos maiores desafios do processamento de informação é o de saber como processar bases de dados cada vez de maior dimensão, com dados complexos e com grandes taxas de crescimento, sem degradar o desempenho do sistema.

- Os Sistemas OLAP ("Online Analytical Processing") disponibilizam mecanismos para a síntese, análise e consolidação dinâmica de grandes volumes de dados multidimensionais.

Estruturas Multidimensionais

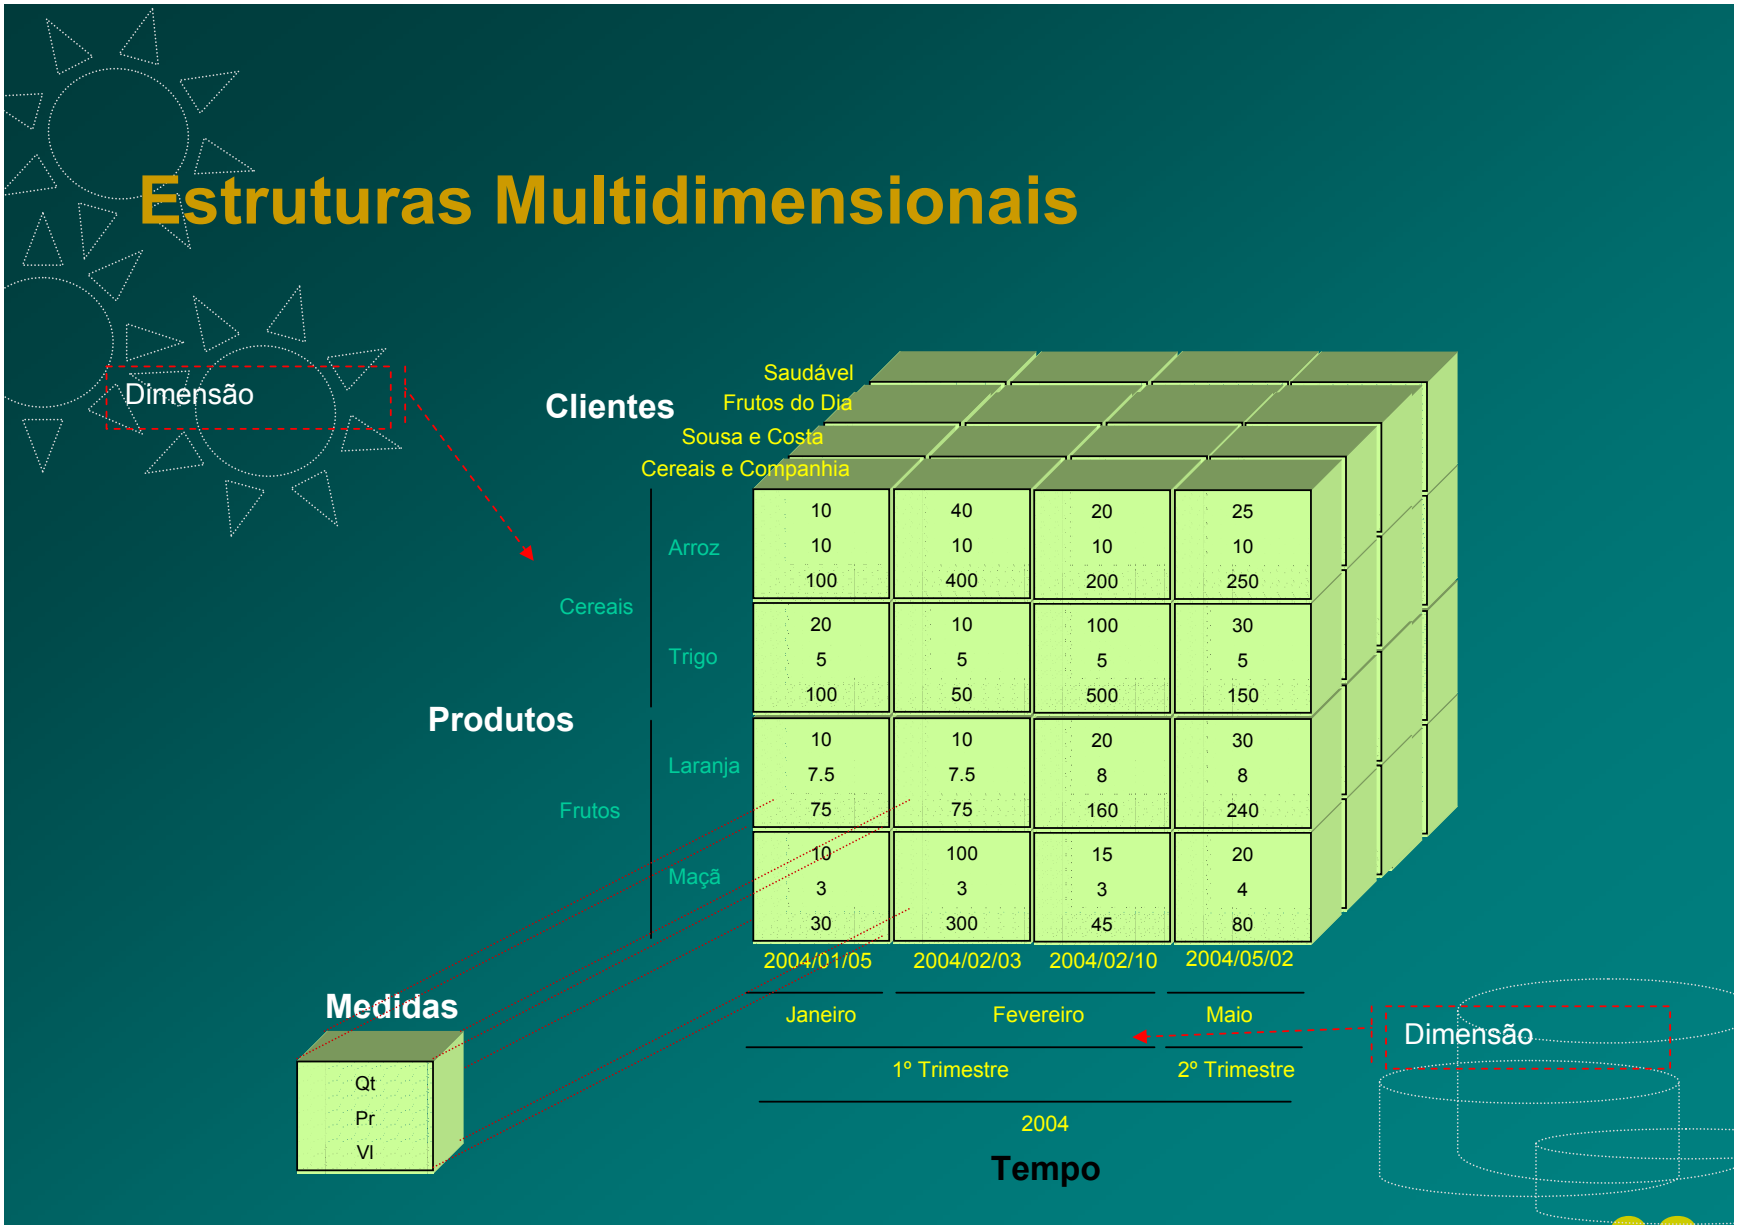

Intervenientes OLAP

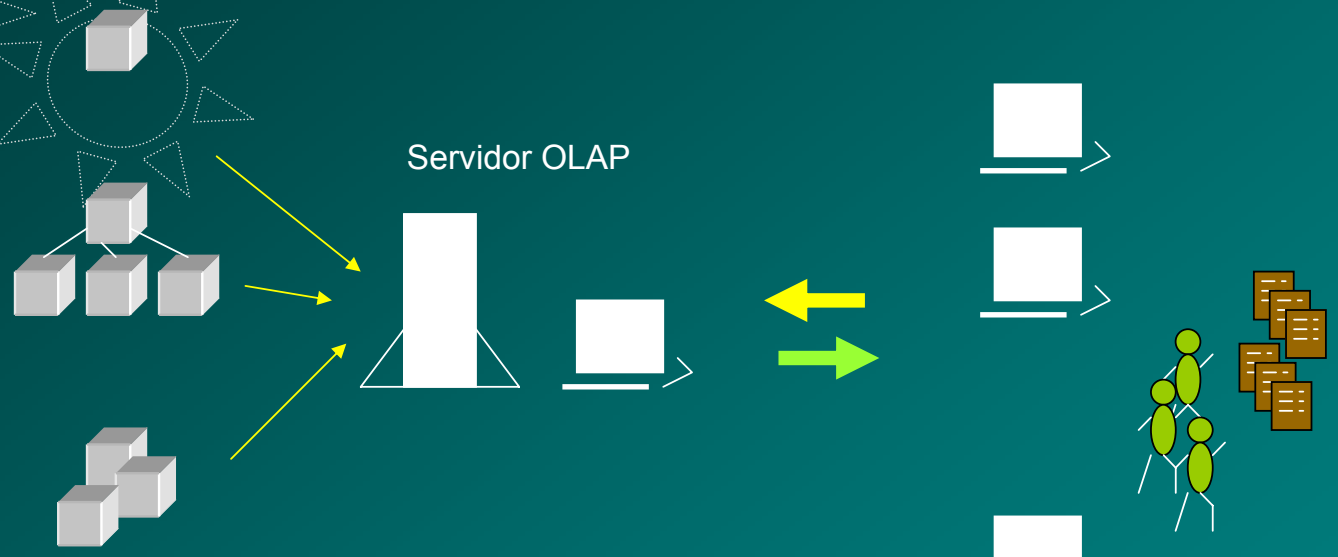

Operações Analíticas

- Os servidores OLAP suportam normalmente um conjunto básico de operações que se podem executar sobre as estruturas multidimensionais definidas e, claro, alimentadas.

- As operações analíticas mais comuns são:
  - Agregação ou consolidação (“Roll-Up”).

    [vendas detalhadas dos produtos] → [vendas por cliente] → [vendas por localidade] → [vendas por região] → [vendas por país]

  - Desagregação ou especialização (“Drill-Down”).

    [vendas por país] → [vendas por região] → [vendas por localidade] → [vendas por cliente] → [vendas detalhadas dos produtos]

  - Cortar e Rodar (“Slicing and Dicing” – “Pivoting”).

Ferramentas OLAP

- As ferramentas OLAP são categorizadas de acordo com a arquitectura do sistema de bases de dados que suporta o processamento analítico.

- Existem três categorias principais:

  - Relacional OLAP (ROLAP)
  - Multidimensional OLAP (MOLAP ou MD-OLAP)
  - Híbrido OLAP (HOLAP)

Regras para Sistemas OLAP

- Vistas conceptuais multidimensionais.
- Transparência.
- Acessibilidade.
- Desempenho consistente na geração de relatórios.
- Arquitectura Cliente-Servidor.
- Dimensionalidade Genérica.
- Manuseamento dinâmico de matrizes dispersas.
- Suporte multiutilizador.
- Operações de cruzamento dimensional não restritas.
- Manipulação de dados intuitiva.
- Geração de relatórios flexível.
- Dimensões e níveis de agregação ilimitados.

Alimentação de Hiper-Cubos

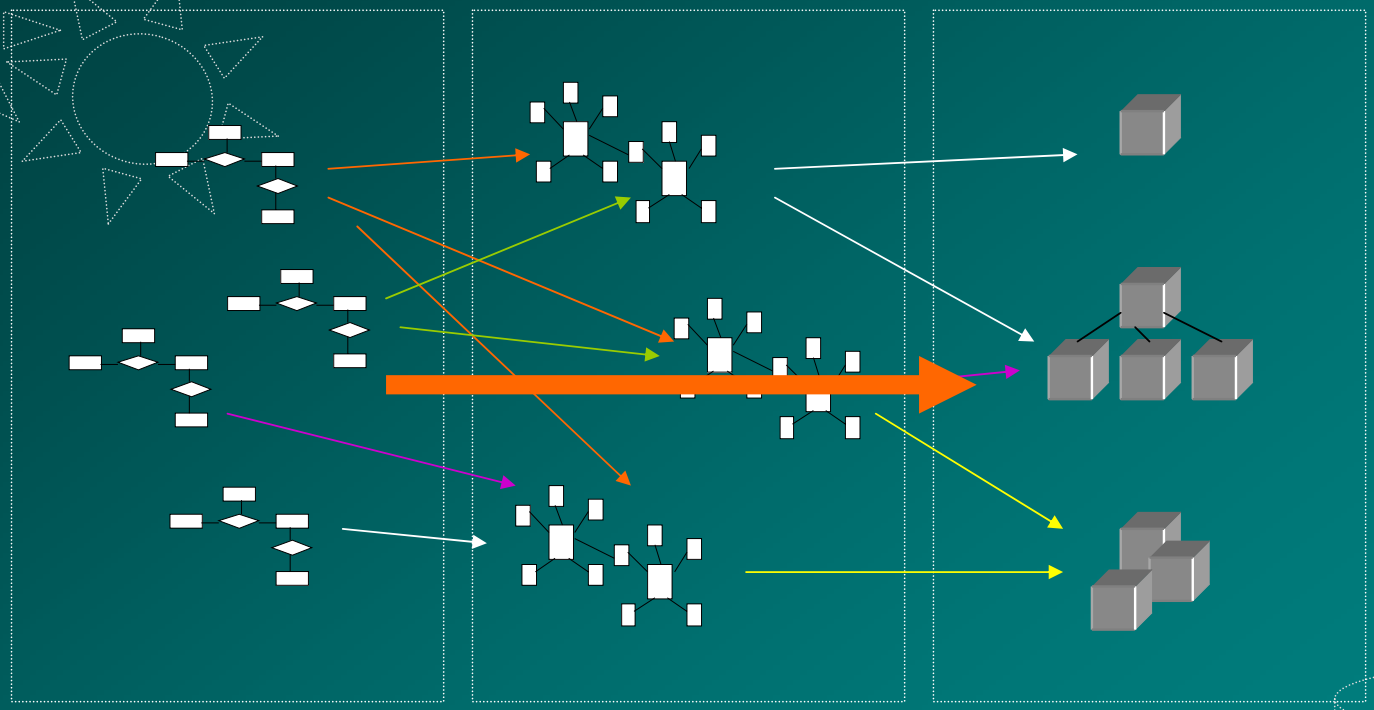

Sistemas Operacionais

Sistema de Data Warehousing

Sistemas de Processamento Analítico

Notas Finais

- Os Sistemas de Data Warehousing são um dos vários tipos de instrumentos que nos últimos anos alguns agentes de decisão têm utilizado e que resolvem, em parte, o problema da dispersão de dados no seio de uma empresa.
- Dada a crescente exigência e heterogeneidade dos processos de decisão dos dias de hoje, a informação que os sistemas operacionais contêm, frequentemente de características "caseiras", é muitas vezes completada com outros dados provenientes de fontes de informação externas.
- Os agentes de decisão precisam de ter meios que lhes garantam facilmente o acesso a todos esses tipos de informação, independentemente da localização das suas fontes.
- As capacidades apresentadas pelos Sistemas de Data Warehousing, na integração de dados consistentes num único repositório de informação, permitem aos agentes de decisão administrar e desenvolver atempadamente funções estratégicas operacionais, assim como obterem dados vitais em tempo útil para suporte aos seus processos de decisão.

Bibliografia

- Kimball, R., Data Warehouse Toolkit : Practical Techniques for Building Dimensional Data Warehouses, John Wiley & Sons, 1996.
- Inmon, W.H., Building the Data Warehouse , John Wiley & Sons,1996.
- Kimball, R., Reeves, L., Ross, M., Thornthwait, W., The Data Warehouse Lifecycle Toolkit - Expert Methods for Designing, Developing, and Deploying Data Warehouses, John Wiley & Sons,1998.
- Connolly, T., Begg, C., Database Systems - A Practical Approach to Design, Implementation, and Management, III Edição, Addison-Wesley, 2002.
- Jarke,M., Lenzerini,M., Vassiliou,Y., Vassiliadis,P., Fundamentals of Data Warehouses, Springer-Verlag, 1998.
- Kimball, R., Merz, R.,Data Webhouse Toolkit : Building the Web-Enabled Data Warehouse, John Wiley, 2000.
- Inmon, W.H., Welch, J.D., Glassey, K.L., Managing the Data Warehouse, John Wiley & Sons, 1997.