Resumo Detalhado – Perfil SDW: CIAD, SETCD e ACAD

Parte 1: CIAD – Conceção e Implementação de Armazéns de Dados

1. Fundamentos e Objetivos

A unidade curricular CIAD tem como principal propósito capacitar os alunos com competências teóricas e práticas para o design e implementação de sistemas de suporte à decisão, com foco na construção de armazéns de dados. A disciplina está fortemente ancorada nas metodologias de Ralph Kimball (modelação dimensional) e Carlo Golfarelli (formalização conceitual), assim como nas práticas modernas de modelação como Data Vault (Dan Linstedt).

O DW é um sistema de informação que reúne dados de diferentes origens para permitir uma análise histórica e orientada à decisão. É usado para consolidar, historizar e organizar grandes volumes de dados, tornando-os acessíveis a ferramentas analíticas.

Necessidade Empresarial de Data Warehousing

- As empresas enfrentam a exigência de processar e avaliar grandes volumes de informação para tomar decisões informadas.
- Adaptação às constantes mudanças e requisitos dos mercados é essencial.
- As bases de dados empresariais, incluindo a conjugação de bases departamentais, são destacadas como fontes valiosas.
- Quando exploradas adequadamente, essas bases podem oferecer vantagens significativas nos segmentos de mercado.
- O objetivo do DW é transformar dados brutos em informações estratégicas, suportando a tomada de decisão.

Desafios das Fontes de Informação

- De acordo com Porter, as fontes de informação empresarial apresentam altos graus de diversidade e heterogeneidade.
- Causas incluem:
    - Coordenação deficitária nos processos de desenvolvimento de software dentro das empresas.

    - Falta de planeamento claro para coleta e armazenamento de dados.
    - Não integração entre funcionalidades empresariais e recursos associados.
    - Características intrínsecas da natureza da informação.
- Esses fatores reforçam a necessidade de um sistema estruturado como o DW para mitigar essas dificuldades.

Desempenho dos Sistemas

- Os sistemas de informação empresarial, com taxas de crescimento acentuadas, tendem a atingir estados de saturação a curto ou médio prazo nos sistemas de bases de dados.
- Limitações de desempenho incluem:
    - Capacidade reduzida de resposta a interrogações complexas, com alto grau de agregação e cálculo, gerando longos períodos de espera pela informação.
    - Sobrecarga causada por um elevado número de transações operacionais, reduzindo o tempo de atenção do sistema para processar consultas.
- Isso destaca a importância de arquiteturas DW otimizadas para suportar análises sem comprometer o desempenho operacional.

Desenho de um Data Warehouse

- O processo de desenho envolve:
    - Identificação dos dados a armazenar no DW, incluindo conhecimento sobre seus formatos lógicos e esquemas dimensionais.
    - Determinação das fontes necessárias para suprir os dados requeridos, com análise de seus formatos lógicos e esquemas conceituais relacionais.
    - Escolha de hardware, software e recursos humanos para a implementação.
- É apresentado como um processo meticuloso que exige alinhamento entre os dados, suas origens e a infraestrutura de suporte.

Operações Analíticas

- Os servidores OLAP suportam operações analíticas sobre estruturas multidimensionais alimentadas por DW.
- Operações comuns incluem:

    - Agregação ou consolidação (Roll-Up), que sumariza de detalhes (ex.: vendas detalhadas de produtos) a níveis superiores (ex.: vendas por cliente, localidade, região, país).
    - Desagregação ou especialização (Drill-Down), que detalha de níveis agregados (ex.: vendas por região) para específicos (ex.: vendas por produto ou cigarro).
    - Cortar e rodar (Slicing and Dicing - Pivoting), que filtra e reorienta os dados para diferentes perspectivas analíticas.
- Essas operações permitem uma exploração flexível e interativa dos dados armazenados.

Ferramentas OLAP

- As ferramentas OLAP são classificadas com base na arquitetura do sistema de bases de dados que suportam o processamento analítico.
- Categorias principais incluem:
    - ROLAP (Relational OLAP), baseado em bases de dados relacionais, adequado para grandes volumes de dados com flexibilidade.
    - MOLAP (Multidimensional OLAP), que utiliza estruturas multidimensionais otimizadas para desempenho em análises rápidas.
    - HOLAP (Hybrid OLAP), que combina ROLAP e MOLAP, oferecendo um equilíbrio entre flexibilidade e performance.
- Essas ferramentas são essenciais para traduzir os dados do DW em insights acionáveis.

Características das Ferramentas OLAP

- Atributos-chave incluem:
    - Vistas conceitualmente multidimensionais para apresentação intuitiva dos dados.
    - Transparência para facilitar o uso sem exigir conhecimento técnico profundo.
    - Acessibilidade para múltiplos usuários.
    - Desempenho consistente na geração de relatórios.
    - Arquitetura cliente-servidor para distribuição de carga.
    - Dimensionalidade genérica para suportar diversas dimensões.
    - Manuseamento dinâmico de matrizes dispersas.
    - Suporte multiusuário para acesso simultâneo.
    - Operações de cruzamento dimensional não restritas para análises entre diferentes dimensões.

    - Manipulação de dados intuitiva com interface amigável.
    - Geração de relatórios flexível para adaptação a diferentes necessidades.
    - Dimensões e níveis de agregação ilimitados para escalabilidade analítica.
- Essas características garantem que as ferramentas OLAP sejam robustas e adaptáveis a diversos cenários empresariais.

Considerações Finais

- Os *data warehouses* são instrumentos utilizados por agentes de decisão para resolver o problema da dispersão de dados dentro das empresas, integrando informações consistentes em um único repositório.
- Diante da crescente exigência e heterogeneidade dos processos de decisão, os dados operacionais (frequentemente "caseiros") são complementados por fontes externas, exigindo meios acessíveis para integração.
- Benefícios incluem:
    - Acesso universal a todos os tipos de informação, independentemente da localização das fontes.
    - Suporte à decisão através da administração de funções estratégicas e operacionais atempadamente, fornecendo dados vitais em tempo útil.
- O texto reforça o DW como uma solução essencial para a gestão integrada de dados e suporte à competitividade empresarial.

2. Arquitetura de Data Warehousing

A arquitetura clássica de um DW é composta por várias camadas e componentes:

- **Fontes de Dados**: sistemas OLTP, bases relacionais, ficheiros CSV, ERPs, CRMs, APIs e sensores IoT.
- **Staging Area**: local intermediário onde os dados são extraídos das fontes, validados, limpos e preparados. Esta camada é fundamental para separar os dados brutos dos dados já tratados.
- **DW Central**: armazém de dados propriamente dito, onde os dados estão organizados de forma integrada, não volátil, historizada e orientada por assunto.
- **Data Marts**: subconjuntos do DW orientados a departamentos (vendas, marketing, logística), otimizados para análises específicas.

- **Ferramentas OLAP/BI**: acesso ao DW é feito através de dashboards, relatórios analíticos, consultas multidimensionais e ferramentas de exploração interativas.

3. Modelação Dimensional (Kimball & Golfarelli)

A modelação dimensional é o modelo mais usado na construção de DW e consiste em organizar os dados em torno de fatos (medidas) e dimensões (contexto).

- **Tabelas de Fatos**: armazenam eventos de negócio mensuráveis (ex: vendas, lucros). Contêm medidas numéricas e chaves estrangeiras para as dimensões.
- **Tabelas de Dimensões**: fornecem o contexto para os fatos, com atributos descritivos (ex: nome do cliente, categoria do produto, localização).

Esquemas típicos:

- **Esquema Estrela**: uma tabela de fato no centro ligada diretamente a várias dimensões.
- **Esquema Floco de Neve**: variação do esquema estrela com dimensões normalizadas em subdimensões.
- **Constelação de Fatos**: vários fatos partilham dimensões comuns (ex: vendas e devoluções usando a dimensão produto).

Outros conceitos essenciais:

- **Grão**: o nível de detalhe de uma tabela de fato (ex: venda por transação vs. venda por dia).
- **Hierarquias Dimensionais**: estruturas organizadas que permitem agregações (ex: Data: Ano > Trimestre > Mês > Dia).
- **Slowly Changing Dimensions (SCD)**:
    - Tipo 1: sobrescreve o valor antigo (sem histórico).
    - Tipo 2: adiciona nova linha com timestamp (mantém histórico completo).
    - Tipo 3: cria coluna para valor anterior (mantém valor atual e anterior).

Tipos de Dimensões Especiais:

- **Degeneradas**: atributos que não têm tabela própria (ex: ID da transação).

- **Role-Playing**: mesma dimensão com diferentes papéis (ex: Data de Encomenda, Data de Entrega).
- **Mini-Dimensões**: dimensões pequenas extraídas de uma maior para otimizar performance (ex: clusterização de clientes).
- **Junk Dimensions**: grupo de atributos diversos sem ligação lógica direta (ex: flags, indicadores binários).
- **Dimensões Conformes**: utilizadas em vários data marts, garantindo consistência dos relatórios.
- **Dimensões Externas (Outsourced)**: fornecidas por entidades externas (ex: scores de crédito).

Notação de Golfarelli: Golfarelli propõe uma formalização gráfica clara para esquemas dimensionais, incluindo representação de cardinalidades, hierarquias, granularidades e vínculos entre fatos e dimensões.

Método dos 4 passos: 1) Seleção da área de suporte à decisão a implementar, 2) Grão, 3) Dimensões, 4) Factos

4. Data Vault e Data Vault 2.0 (Dan Linstedt)

O **Data Vault** é uma metodologia de modelação de dados desenvolvida por Dan Linstedt para ambientes de *Data Warehousing* empresariais. Foi concebida para responder aos desafios típicos de sistemas que lidam com múltiplas fontes de dados heterogéneos, mudanças frequentes nos requisitos de negócio, auditoria e escalabilidade a nível de big data.

Princípios do Data Vault

- **Separação de responsabilidades** entre diferentes tipos de informação: chaves de negócio, relações e atributos descritivos.
- **Total rastreabilidade e auditabilidade**: todos os dados são armazenados com timestamp e origem.
- **Agilidade e flexibilidade**: fácil adaptação a mudanças sem remodelação global.
- **Modelação altamente normalizada**, mas com suporte posterior à conversão em esquemas dimensionais.

Estrutura do Modelo

O modelo baseia-se em três tipos principais de entidades:

- **Hubs**
    - Representam entidades de negócio (ex: Cliente, Produto).

    - Contêm **apenas a business key**, um timestamp de carga e a origem do dado.
    - Têm um identificador único, normalmente gerado por *hashing* da business key.
    - Não contêm atributos descritivos (sem dependência de mudanças).

- **Links**
    - Representam **relações entre dois ou mais hubs** (ex: Cliente fez Encomenda).
    - Incluem as *foreign keys* para os hubs envolvidos, além de metadata técnica (timestamp, source).
    - Suportam relacionamentos binários ou n-ários (muitos para muitos).
    - A adição de novas relações não requer alterações estruturais nos hubs existentes.
- **Satélites**
    - Contêm **atributos descritivos e históricos** associados a um hub ou a um link.
    - Suportam versionamento natural (ex: SCD Tipo 2).
    - É possível ter múltiplos satélites para separar diferentes conjuntos de atributos (ex: atributos sensíveis, atributos de negócio, atributos operacionais).
    - Permitem **inserção paralela**, já que não afetam outras tabelas.

Vantagens do Data Vault

- **Auditabilidade nativa**: todos os dados são armazenados com origem e timestamp, suportando conformidade (ex: GDPR, HIPAA).
- **Alta escalabilidade**: suporta ingestão massiva, paralela e incremental.
- **Adaptável a mudança**: novos atributos são adicionados via novos satélites, sem afetar estruturas existentes.
- **Separação clara de preocupações**: facilita o desenvolvimento e manutenção do modelo.
- **Facilidade de integração com Data Lakes**: armazena dados em estado bruto (raw) de forma natural.

Data Vault 2.0 – Evolução e Modernização

Apresentado por Linstedt e Michael Olschimke, o **Data Vault 2.0** é uma extensão e refinamento do modelo original. Introduz novos componentes arquiteturais e adaptações a tecnologias emergentes.

Novos Conceitos

- **Raw Vault**: contém dados brutos oriundos das fontes, sem regras de negócio aplicadas. É a versão mais pura e auditável dos dados.
- **Business Vault**: aplica regras de negócio sobre o raw vault para derivar dados agregados, calculados ou normalizados (ex: status de cliente ativo/inativo).
- **Information Marts**: saídas modeladas (star schema ou vistas analíticas) para consumo por ferramentas de BI ou analistas.
- **Persistent Staging Area (PSA)**: camada anterior ao Raw Vault onde dados extraídos são armazenados tal como vêm das fontes.

Avanços Técnicos

- **Suporte a big data**: compatível com Hadoop, Spark, NoSQL, cloud-native (AWS, Azure, GCP).
- **Uso de hashing** para chaves (hash keys): permite garantir unicidade, anonimização e escalabilidade em ambientes distribuídos.
- **Parallel loading**: as tabelas podem ser carregadas de forma paralela (sem dependências entre satélites e links).
- **Automação e DevOps**: incentiva a construção de pipelines CI/CD para ingestão e validação de dados.

Alinhamento com Arquiteturas Modernas

- O Data Vault 2.0 encaixa-se naturalmente na **Data Lakehouse Architecture**, especialmente na camada silver da **Medallion Architecture**.
- **Complementar a Data Lakes**: estrutura a informação armazenada de forma caótica nos lagos de dados, acrescentando qualidade e contexto.
- **Ideal para ambientes em mudança rápida**, como sistemas ERP em constante evolução.

Característica	Data Vault	Star Schema	3NF
Suporte a histórico	Sim (via satélites)	Parcial (SCDs)	Sim, mas complexo
Flexibilidade a mudanças	Alta	Baixa	Moderada
Suporte a big data	Total	Limitado	Fraco
Carregamento paralelo	Sim	Limitado	Limitado
Governança/Auditabilidade	Alta	Média	Alta
Complexidade inicial	Alta	Baixa	Alta
Tempo de query	Maior (sem mart)	Otimizado	Fraco para análises

5. Qualidade dos Dados, Segurança e Metadados

Qualidade de Dados: Fundamental para garantir que as análises baseadas no DW são corretas. Inclui:

- **Completude**: ausência de valores nulos onde não são permitidos.
- **Consistência**: coerência entre diferentes fontes e períodos.
- **Precisão**: os dados representam fielmente a realidade.
- **Integridade**: todas as chaves e relações são mantidas corretamente.
- **Validade**: dados respeitam regras de negócio e formatos.

Metadados: Essenciais para rastrear e documentar o ciclo de vida dos dados.

- **Metadados Técnicos**: estruturas, tipos de dados, índices.
- **Metadados Operacionais**: logs de execução, tempos de carga, erros.
- **Metadados Semânticos**: significado dos campos e relações.

Segurança e Governança:

- **Controlo de Acessos**: perfis de utilizador, segregação de funções.
- **Auditoria e Logs**: registo de alterações, execuções, acessos.
- **Backups e Recuperação**: proteção contra falhas e perda de dados.
- **Data Stewardship**: responsabilização pela qualidade e significado dos dados

Parte 2: SETCD – Sistemas de Extração, Transformação e Carregamento de Dados

1. Data Pipelines e Integração

Pipelines de dados são sistemas automatizados que movem dados de múltiplas fontes até um destino analítico, garantindo consistência, rastreabilidade e transformação adequada. Eles são essenciais para alimentar sistemas analíticos e plataformas de BI com dados confiáveis e atualizados.

Tipos de pipelines:

- **Batch**: dados são processados em grandes volumes, com frequência programada (diária, semanal). Ideal para relatórios periódicos e cargas completas.
- **Real-time (streaming)**: ingestão e processamento contínuo à medida que os dados são gerados. Utiliza tecnologias como Apache Kafka, Spark Streaming, Kinesis.
- **Micro-lote**: processamento em pequenos lotes com alta frequência (ex: a cada 10 segundos), equilibrando performance e latência.

Etapas e requisitos de construção:

- Análise de objetivos de negócio.
- Estudo do contexto e das fontes de dados (formatos, volume, frequência).
- Identificação de operações necessárias (transformações, filtragem, joins).
- Planeamento da orquestração e paralelismo das tarefas (usando ferramentas como Airflow, Apache NiFi).
- Automação e monitorização contínua para garantir confiabilidade.

2. Ingestão de Dados e CDC (Change Data Capture)

A ingestão representa o processo de recolher dados brutos e transferi-los para um sistema centralizado, como um data lake ou DW. Existem vários modos:

- **Total (full)**: transfere todos os dados das fontes, útil para pequenas bases ou cargas iniciais.
- **Incremental**: transfere apenas novos ou alterados dados com base em chaves de atualização ou timestamps.

- **CDC**: técnica avançada que deteta mudanças diretamente dos logs de transações de bases de dados (insert, update, delete), permitindo:
    - Baixa latência.
    - Integridade transacional.
    - Eficiência de recursos.
    - Uso em ingestão em tempo real.

Ferramentas comuns incluem Debezium, Oracle GoldenGate e serviços nativos de cloud (AWS DMS, Azure Data Factory).

3. Áreas de Preparação de Dados (Staging & Buffer Zones)

São zonas temporárias para armazenamento, tratamento e bufferização de dados antes da carga no sistema analítico.

Objetivos principais:

- Permitir armazenamento temporário e isolamento entre fontes e destino.
- Aplicar regras de qualidade de dados: remoção de duplicados, verificação de integridade, normalização.
- Reduzir a latência entre ingestão e consumo.
- Gerar logs de auditoria e rastreabilidade.
- Preparar os dados para transformação posterior (batch ou streaming).

4. Transformações e Qualidade dos Dados

As transformações preparam os dados para uso analítico e operacional.

Tipos de transformações comuns:

- **Agregações**: sumarizar dados por grupo (ex: total de vendas por região).
- **Lookup e joins**: cruzamento com outras tabelas para enriquecimento.
- **Criação de chaves substitutas (surrogate keys)**.
- **Eliminação de duplicados**.
- **Normalização e padronização de formatos** (datas, nomes, codificações).
- **Tratamento de erros e inconsistências** (valores inválidos, nulos, outliers).

Dimensões da qualidade de dados:

- **Completude**: ausência de campos vazios.
- **Atualidade (Timeliness)**: dados disponíveis a tempo.

- **Validade**: conformidade com regras (ex: formatos de emails).
- **Precisão**: veracidade da informação.
- **Consistência**: coerência entre sistemas.
- **Integridade**: relações bem definidas e respeitadas.

5. Migração de Dados

Migração é o processo de mover dados de sistemas legados ou antigos para novos ambientes (ex: ERP novo, DW cloud). Distingue-se por ser geralmente um evento **pontual**, ao contrário da integração contínua.

Fases da migração:

1. **Análise e descoberta**: levantamento de fontes, estruturas, qualidade e regras de negócio.
2. **Extração e perfilagem**: uso de ferramentas de data profiling para entender padrões, outliers, duplicados.
3. **Limpeza (cleansing)**: remoção de redundâncias, parsing de campos complexos, conversão de dados.
4. **Validação pré-carga**: geração de relatórios, sessões de aprovação com utilizadores.
5. **Carga (load)**: uso de ferramentas específicas (LSMW, IDocs, scripts, ETL dedicados).
6. **Reconciliação**: comparação entre dados de origem e destino; testes de integridade; sign-off do negócio.

Estratégias:

- **Big Bang**: tudo de uma vez. Maior risco, menos complexidade de sincronização.
- **Trickle**: fases incrementais. Menos risco, mas maior esforço de gestão paralela.

6. Fatores Críticos de Sucesso

- **Documentação e conhecimento das fontes/destino.**
- **Perfilagem detalhada** para prever erros e mapear regras.
- **Testes contínuos** e execuções mock.
- **Automatização com pipelines repetíveis e auditáveis.**
- **Validações robustas (pré e pós carga)** com estatísticas e feedback do negócio.

- **Envolvimento das equipas de negócio** com aprovação formal dos dados.

7. Arquiteturas de Armazenamento: Data Warehouse, Data Lake e Data Lakehouse

Data Warehouse (DW):

- Estrutura rígida com esquema definido (schema-on-write).
- Ideal para BI, reporting, dashboards.
- Dados normalizados e curados.
- Suporta ETL.

Data Lake:

- Armazena dados em formato bruto.
- Suporta esquemas dinâmicos (schema-on-read).
- Escalabilidade horizontal e baixo custo.
- Ideal para ML, AI, análise exploratória.

Data Lakehouse:

- Combina a flexibilidade do Data Lake com a performance e governança do DW.
- Suporta workloads mistos (BI, ML, batch, streaming).
- Oferece ACID transactions, metadata rica, time travel e schema enforcement.
- Formatos: Delta Lake, Iceberg, Parquet.
- Ferramentas: Databricks, Snowflake, Synapse, Redshift + S3.

8. Migração e Gestão de Data Lakehouse

Vantagens:

- Redução de silos e redundância.
- Apoio nativo a BI e ciência de dados.
- Custos reduzidos com armazenamento desacoplado.
- Governança e segurança integradas.

Boas práticas de migração:

- Redefinir acessos com RBAC.
- Garantir spin-up eficiente dos motores (auto-scale, serverless).

- Validar dados automaticamente.
- Automatizar ingestão e transformação.
- Usar APIs abertas e formatos abertos (evitar vendor lock-in).
- Começar com cargas pequenas e escalar.

Arquitetura típica de Lakehouse:

- Camada de ingestão (batch e streaming).
- Camada de armazenamento (formato bruto > refinado).
- Metadata + transações ACID.
- APIs de consumo (BI, notebooks, ML pipelines).
- Governança transversal (segurança, linagem, auditoria).

Esta abordagem híbrida reflete a evolução das necessidades atuais em análise de dados: flexibilidade, velocidade e qualidade de informação num único ambiente controlado.

Analytical Sandboxes (Caixas de Areia Analíticas)

Os *analytical sandboxes* são componentes fundamentais em arquiteturas modernas de data warehousing orientadas à análise exploratória, ciência de dados e inovação analítica. Permitem isolar atividades experimentais do ambiente produtivo, garantindo liberdade de análise com controlo e segurança.

Definição e Propósito

- São ambientes isolados e temporários destinados à análise de dados fora da operação principal do datawarehouse.
- Permitem a criação, teste e validação de modelos analíticos sem impactar negativamente os sistemas produtivos.
- Usados por analistas, cientistas de dados, engenheiros de dados e até por áreas de negócio para análises ad-hoc.

Principais Características

- **Isolamento**: operam fora do repositório central (DW/Data Lake), protegendo o sistema de produção contra cargas excessivas ou erros de scripts.
- **Flexibilidade**: permitem integrar dados internos e externos, realizar transformações personalizadas e aplicar diferentes técnicas analíticas (estatísticas, machine learning, etc.).

- **Ambiente controlado**: embora livres, seguem regras de governança, incluindo acesso autorizado, logs, quotas de recursos e tempo de retenção.

Dados Disponíveis

- **Dados brutos**: extraídos diretamente de fontes transacionais ou do data lake, ainda sem tratamento.
- **Dados refinados**: previamente transformados no data warehouse.
- **Dados externos**: como APIs públicas, datasets de parceiros ou ficheiros manuais.
- Estes dados podem ser usados em conjunto, permitindo análises híbridas e enriquecimento de modelos.

Ferramentas e Tecnologias Utilizadas

- Notebooks interativos como **Jupyter**, **RStudio**, **Apache Zeppelin**.
- Linguagens de programação como **Python**, **R**, **SQL** ou **Scala**.
- Motores de processamento como **Spark**, **Presto**, **Snowflake**, **Databricks**, entre outros.
- Plataformas colaborativas como **Dataiku**, **KNIME**, **Google Colab** para projetos em equipa.

Casos de Uso

- **Exploração de dados** (data discovery).
- **Criação e treino de modelos preditivos** (machine learning).
- **Prototipagem de novos indicadores ou relatórios**.
- **Testes de integração de novas fontes de dados**.
- **Simulação de regras de negócio** e cenários hipotéticos.

Boas Práticas

- Definir limites de uso (tempo, recursos, armazenamento).
- Assegurar auditoria e rastreabilidade de ações.
- Documentar scripts e processos para posterior reutilização ou promoção para produção.
- Garantir políticas de segurança e proteção de dados sensíveis (ex.: anonimização).

Vantagens

- Promove **agilidade analítica** e experimentação rápida.
- Facilita a **validação de hipóteses** com dados reais.
- Permite desenvolver soluções com menos dependência da equipa de TI.
- Estimula a **inovação** e **descoberta de valor** nos dados.

Desafios

- Risco de **divergência com a produção** se não houver controlo.
- Possibilidade de duplicação de esforços ou redundância analítica.
- **Custos elevados** se mal geridos (uso excessivo de recursos).
- Requer integração com **ferramentas de governança e catalogação** para não se tornar um "pântano analítico".

Data Swamps (Pântanos de Dados)

Um **Data Swamp** representa o oposto de um data lake bem governado — é um repositório desorganizado de dados que perdeu a sua utilidade analítica devido à falta de estrutura, curadoria e governança. O termo transmite a ideia de um lago de dados que, por má gestão, se transforma num pântano onde os dados "afundam" e se tornam inutilizáveis.

Definição

- Um *data swamp* é um repositório de dados que:
    - Está sobrecarregado com dados mal catalogados ou não estruturados.
    - Carece de documentação, metadados e mecanismos de governança.
    - É difícil de consultar, explorar ou analisar de forma eficaz.

Como se forma um Data Swamp

- **Falta de Governança**: ausência de regras claras sobre quem pode carregar dados, com que formatos e com que validações.
- **Ingestão descontrolada**: ingestão massiva de dados brutos sem normalização, limpeza ou organização.
- **Ausência de Metadados**: sem descrições, origem ou contexto dos dados, torna-se difícil saber o que significam ou como usá-los.
- **Redundância e Inconsistência**: múltiplas cópias dos mesmos dados com pequenas variações e versões desatualizadas coexistem.
- **Esquemas indefinidos ou inconsistentes**: diferentes estruturas e formatos para dados similares, dificultando a integração.

Sinais de que estás num Data Swamp

- É difícil encontrar o dataset certo para análise.
- Dados com nomes confusos ou inconsistentes.
- Dados duplicados, corrompidos ou incompletos.
- Desconfiança generalizada dos dados por parte dos analistas.
- Consultas são lentas, ineficientes ou retornam resultados inesperados.

Riscos e Impactos

- **Desperdício de recursos**: armazenamento e processamento de dados inúteis.
- **Perda de confiança** nos dados por parte das equipas de negócio.
- **Atrasos em projetos** analíticos por falta de clareza ou acessibilidade.
- **Problemas de compliance** (ex: GDPR) devido a dados não rastreáveis ou sem controlo de acesso.
- **Barreiras à inovação**, já que os dados estão "enterrados" e não são reutilizáveis.

Característica	Data Lake	Data Swamp
Estrutura	Organizado por camadas e zonas	Dados depositados sem estrutura
Metadados	Presentes, bem definidos	Ausentes ou incompletos
Governança	Com políticas e controlo de acesso	Inexistente ou mal implementada
Qualidade dos dados	Curados, validados	Brutos, redundantes, errados
Utilização	Alta reutilização e confiança	Baixa usabilidade

Boas práticas para evitar Data Swamps

- **Estabelecer um catálogo de dados** com metadados bem definidos (ex: com ferramentas como Apache Atlas, DataHub, Collibra).
- **Controlar a ingestão** com validações, padronizações e regras de qualidade.
- **Implementar políticas de ciclo de vida dos dados**: arquivar, limpar ou eliminar dados obsoletos.
- **Classificar e particionar dados** para facilitar consultas e manter performance.
- **Auditar e monitorizar o uso** de datasets para evitar redundância e promover reutilização.

Remediar um Data Swamp

- Iniciar um **data audit** para identificar dados úteis vs irrelevantes.
- Catalogar datasets com ajuda de analistas e utilizadores de negócio.
- Implementar camadas no data lake (raw, curated, trusted).
- Integrar mecanismos de **governança ativa** com workflows de aprovação para novos dados.

Parte 3: ACAD – Aquisição de Conhecimento em Armazéns de Dados

1.Regras de Associação

As Regras de Associação são uma técnica de descoberta de conhecimento em bases de dados (KDD) usada para identificar padrões frequentes e relações entre variáveis em grandes conjuntos de dados. Seguem a estrutura:
SE <condição> ENTÃO <conclusão>.

Definição e Objetivos

- Procuram padrões frequentes, correlações e relações de coocorrência entre itens ou atributos.
- São amplamente utilizadas para entender hábitos de consumo (market basket analysis), prever comportamentos e melhorar decisões de negócio.

Exemplos

- Se um cliente compra ovos, a probabilidade de comprar leite é de 80%.
- Caso clássico: "fraldas e cerveja" — homens entre 30-40 anos, comprando fraldas à sexta-feira à tarde, têm alta probabilidade de também comprar cerveja.

Aplicações

- Análise de consumo e disposição de produtos em loja (store layout).
- Promoções e vendas cruzadas (cross-marketing).
- Deteção de fraudes.
- Definição de catálogos sazonais.

Estrutura das Regras

- **Formato**: Antecedente → Consequente [Suporte, Confiança]
- **Suporte**: frequência da regra no dataset (% de casos em que antecedente e consequente ocorrem juntos).
- **Confiança**: probabilidade de o consequente ocorrer dado o antecedente (% de casos com antecedente em que o consequente também ocorre).

Exemplo:

- Regra: computador → gescliente [2%, 60%]
    - Suporte: 2% — 2% das transações envolvem ambos.
    - Confiança: 60% — 60% dos que compraram computador também compraram "gescliente".

Tipos de Regras

- **Booleanas**: indicam presença/ausência (ex: computador → gescliente).

- **Quantitativas**: associam intervalos numéricos (ex: idade 30–39 → compra de portátil).
- **Uni-dimensionais**: regras numa única dimensão (ex: apenas "compra").
- **Multi-dimensionais**: combinam diferentes atributos (ex: compra + tipo de cliente).
- **Multi-nível**: diferentes níveis de abstração (ex: portátil vs computador).

Algoritmo Apriori

- Algoritmo clássico de descoberta de regras:
  - Identifica itemsets frequentes.
  - Usa os princípios:
    - **Subconjunto frequente**: qualquer subconjunto de um itemset frequente também é frequente.
    - **Superset não frequente**: nenhum superset de um itemset não frequente é frequente.
- Geração de regras:
  - A partir de um itemset frequente (ex: ACD), derivam-se todas as combinações possíveis de antecedentes e consequentes (ex: A→CD, AC→D, etc.).

Medidas de Interesse

- **Subjetivas**:
  - Surpresa, novidade e utilidade da regra.
- **Objetivas**:
  - **Suporte**: frequência da regra.
  - **Confiança (confidence)**: precisão da regra.
  - **Lift**: mede correlação (independência se =1, >1 se dependente).
    - Lift(A→C) = Sup(A,C) / (Sup(A) × Sup(C))
  - **Convicção**: mede implicação inversa.
    - Conviction(A→C) = (Sup(A) × Sup(¬C)) / Sup(A,C)
  - **Leverage (Potência)**: mede a diferença entre suporte observado e esperado.
    - Leverage(A→C) = Sup(A,C) – Sup(A) × Sup(C)
  - **Coverage (Amplitude)**: frequência do antecedente.

Exemplos Reais de Aplicação

- Utilizando datasets discretizados com atributos como temperatura, humidade, vento e variável-alvo “jogar”, analisaram-se regras como:
  - Humidade=Normal, Vento=Falso → Jogar=Sim
  - Aspeto=Sol, Humidade=Elevada → Jogar=Não
  - Temp.=Frio, Humidade=Normal → Jogar=Sim

2. Metodologias (CRISP-DM e SEMMA)
As metodologias **CRISP-DM (Cross Industry Standard Process for Data Mining)** e **SEMMA (Sample, Explore, Modify, Model, Assess)** são fundamentais no ciclo de vida da descoberta de conhecimento em bases de dados (KDD):

- **CRISP-DM** é uma metodologia amplamente usada que estrutura projetos de data mining em 6 fases:
    - **Compreensão do Negócio**: definição dos objetivos e requisitos de sucesso do projeto.
    - **Compreensão dos Dados**: recolha, descrição, exploração e verificação da qualidade dos dados.
    - **Preparação dos Dados**: seleção de dados relevantes, transformação, limpeza e formatação.
    - **Modelação**: aplicação de algoritmos (ex. regressão, árvores de decisão, clustering).
    - **Avaliação**: validação da performance e alinhamento com os objetivos iniciais.
    - **Implementação**: integração dos resultados nos sistemas de apoio à decisão.
- **SEMMA**, metodologia da SAS, é mais orientada à execução:
    - **Sample**: extração de amostras representativas dos dados.
    - **Explore**: exploração estatística e visual dos dados (outliers, distribuições).
    - **Modify**: transformação e engenharia de atributos.
    - **Model**: construção e treino de modelos.
    - **Assess**: avaliação da precisão e utilidade dos modelos.

3. Preparação de Dados para Análise
Esta fase é crucial para garantir a qualidade dos modelos:

- **Discretização**: transformação de variáveis contínuas em categorias discretas.
- **Limpeza de Dados**: remoção ou imputação de valores nulos, duplicados e inconsistentes.
- **Transformações**: incluem normalização, padronização, suavização e agregações.
- **Redução de Dimensionalidade**:
    - **PCA (Principal Component Analysis)**: reduz a dimensão preservando variância.
    - **ICA (Independent Component Analysis)**: separa sinais independentes.
- **Engenharia de Atributos (Feature Engineering)**: criação de novos atributos a partir de data, geolocalização, codificações categóricas, etc.
- **Seleção de Atributos**: identificação dos atributos mais relevantes para melhorar a performance e reduzir o overfitting.

4. Segmentação e Clustering
Técnicas de agrupamento **não supervisionadas** para identificação de padrões:

- **K-means**: agrupa os dados em K clusters com base na média dos pontos.
- **K-medoids**: semelhante ao K-means, mas utiliza pontos reais como centros (mais robusto a outliers).
- **DBSCAN**: identifica clusters com base em densidade; detecta outliers e clusters de forma arbitrária.
- **Algoritmos Hierárquicos**:
    - **AGNES (bottom-up)**: começa com cada ponto como cluster e junta iterativamente.
    - **DIANA (top-down)**: começa com todos os pontos num único cluster e divide.

Avaliação da Qualidade dos Clusters:

- **Método do Cotovelo (Elbow Method)**: determina o número ótimo de clusters através da análise da variância explicada.
- **Silhouette Score**: mede a separação entre clusters e a coesão interna (valores próximos de 1 são melhores).

5. Sistemas de Recomendação
Sistemas que sugerem itens personalizados a utilizadores com base no seu histórico, contexto e características dos produtos.

- **Filtragem Colaborativa (Collaborative Filtering)**:
    - **Baseada em Utilizadores**: compara perfis de utilizadores semelhantes.
    - **Baseada em Itens**: recomenda itens semelhantes aos já consumidos.
    - **Problemas**: *Cold start*, escalabilidade, falta de diversidade.
- **Filtragem Baseada em Conteúdo (Content-Based Filtering)**:
    - Baseia-se nas características dos itens e preferências individuais do utilizador.
    - Pode levar à "falta de novidade" (excesso de recomendações semelhantes).
- **Sistemas Híbridos**: combinam várias abordagens para ultrapassar limitações. Tipos:

  Hibridização Ponderada (Weighted Hybrid)

- **Como funciona**: Combina os scores ou rankings gerados por diferentes algoritmos (ex: content-based + collaborative) com pesos atribuídos a cada um.
- **Exemplo**: Score final = 0.6 × Score_CB + 0.4 × Score_CF
- **Vantagem**: Fácil de implementar e ajustar. Pode adaptar-se automaticamente com técnicas de machine learning (ex: regressão, boosting).
- **Desvantagem**: Pode exigir validação extensiva para calibrar pesos corretamente.

Hibridização em Cascata (Cascade Hybrid)

- **Como funciona**: Um algoritmo primário produz um conjunto inicial de recomendações, que é depois refinado por um segundo algoritmo.
- **Exemplo**: Primeiro, um sistema content-based sugere 100 produtos relevantes; em seguida, um collaborative filtering ordena esses produtos de acordo com a popularidade entre utilizadores semelhantes.
- **Vantagem**: Permite uma filtragem mais seletiva e hierárquica — útil em contextos com requisitos de precisão elevada.
- **Desvantagem**: Maior complexidade computacional e risco de descarte de recomendações relevantes na primeira etapa.

Hibridização Mista (Mixed Hybrid)

- **Como funciona**: Apresenta as recomendações de múltiplos sistemas de forma conjunta ao utilizador, sem integração explícita dos resultados.
- **Exemplo**: A interface mostra numa secção filmes baseados nas preferências de utilizadores semelhantes (collaborative) e noutra secção recomendações baseadas nos géneros mais vistos pelo utilizador (content-based).
- **Vantagem**: Transparência para o utilizador; pode facilitar o controlo de diversidade.
- **Desvantagem**: Pode gerar redundância ou confusão se os sistemas recomendarem itens muito semelhantes ou divergentes.

Hibridização em Meta-Nível (Meta-level Hybrid)

- **Como funciona**: O output de um sistema serve como input para outro. Ou seja, um algoritmo aprende um modelo que é usado por outro.
- **Exemplo**: Um modelo baseado em conteúdo é usado para treinar um classificador que, depois, serve como base para um sistema colaborativo.
- **Vantagem**: Grande flexibilidade e possibilidade de exploração de padrões complexos.
- **Desvantagem**: Alta complexidade técnica; exige integração estreita entre modelos.

Hibridização por Seleção Adaptativa (Switching / Adaptive Hybrid)

- **Como funciona**: O sistema escolhe dinamicamente qual algoritmo usar com base no contexto, na disponibilidade de dados ou no perfil do utilizador.
- **Exemplo**: Se o utilizador é novo (cold start), usa-se um sistema content-based. Para utilizadores com muitas interações, usa-se collaborative filtering.
- **Vantagem**: Eficiência e resiliência a problemas típicos de recomendação.
- **Desvantagem**: Requer um mecanismo de decisão (ex: regras, árvore de decisão, heurísticas ou modelos supervisionados).

- **Outras abordagens**:
    - **Demográficos**: agrupam utilizadores por idade, género, localização.
    - **Baseados em Conhecimento**: regras explícitas e modelos de preferência.
    - **Baseados em Utilidade**: estimam o valor esperado dos itens.
    - **Contextuais**: ajustam recomendações com base em hora, localização, dispositivo.

Exemplos Práticos:

- **Netflix**: usa sistemas híbridos com ml e dados de visualização.
- **Spotify**: personaliza com base em interações (play, skip, save).
- **Amazon**: recomenda com base em histórico de compras e visualizações.
- **YouTube**: algoritmo ajustado por watch time e surveys de satisfação.
- **Ebay**: personalização com base em cliques e navegação.